

RESEARCH OUTLINE

Nghiên cứu khả năng bổ sung giữa đặc trưng toàn ảnh, đặc trưng cục bộ và dấu vết forensic trong phát hiện khuôn mặt do AI tạo

1. Tổng quan bài toán nghiên cứu

Bài toán của nhóm là phân biệt khuôn mặt thật và khuôn mặt do AI tạo hoặc chỉnh sửa. Thách thức chính không chỉ nằm ở việc đạt accuracy cao trên tập dữ liệu có cùng phân phối với tập huấn luyện, mà còn ở khả năng **generalization sang những nguồn ảnh AI chưa từng xuất hiện trong quá trình huấn luyện**.

Một model có thể đạt kết quả tốt trên tập validation thông thường nhưng thực tế chỉ học các dấu hiệu riêng của một generator, chất lượng JPEG, resolution hoặc cách xử lý dữ liệu. Khi gặp ảnh đến từ một nguồn sinh mới, những dấu hiệu này có thể thay đổi và hiệu quả của model giảm đáng kể.

Vì vậy, nghiên cứu này lựa chọn khả năng generalization sang nguồn sinh chưa từng thấy làm mục tiêu đánh giá chính. Bên cạnh đó, nhóm cũng xem xét độ bền của model trước một số biến đổi phổ biến như JPEG, resize, blur và crop.

2. Tổng quan các hướng nghiên cứu hiện tại

Từ các paper đã tổng hợp, có thể thấy các nghiên cứu hiện nay đang tiếp cận bài toán theo một số hướng chính.

Hướng thứ nhất sử dụng các model đã được huấn luyện trước như CLIP hoặc DINO để lấy đặc trưng ảnh. Các model này có ưu điểm là đã học được representation thị giác tổng quát từ lượng dữ liệu lớn, do đó thường có khả năng generalization tốt hơn so với việc huấn luyện một mạng mới hoàn toàn trên tập dữ liệu nhỏ.

Hướng thứ hai tập trung vào thông tin cục bộ. Thay vì chỉ sử dụng một representation đại diện cho toàn ảnh, các nghiên cứu khai thác đặc trưng tại từng vùng nhỏ để tìm những bất thường chỉ xuất hiện ở một số vị trí nhất định.

Hướng thứ ba sử dụng các dấu vết mức thấp của ảnh như residual hoặc thông tin tần số. Các đặc trưng này ít tập trung vào nội dung khuôn mặt mà chú ý nhiều hơn tới texture, noise và những dấu vết còn lại từ quá trình sinh ảnh.

Ngoài ra, một số nghiên cứu gần đây cũng chỉ ra rằng quá trình fine-tuning cần được kiểm soát. Với tập dữ liệu nhỏ, fine-tuning quá mạnh có thể khiến model thích nghi tốt với tập train nhưng làm giảm khả năng generalization.

3. Vấn đề nghiên cứu

Điểm chung của các hướng trên là mỗi loại representation có khả năng nắm bắt một loại thông tin khác nhau.

Đặc trưng toàn ảnh giúp model hiểu cấu trúc và nội dung tổng thể. Đặc trưng cục bộ có thể phát hiện bất thường ở những vùng nhỏ. Trong khi đó, residual hoặc các dấu vết mức thấp có thể chứa thông tin mà các representation thị giác thông thường không thể hiện rõ.

Tuy nhiên, việc đơn giản ghép nhiều loại đặc trưng vào cùng một model chưa đủ để hình thành một câu hỏi nghiên cứu chặt chẽ. Nếu kết quả cuối cùng tăng, sẽ khó xác định sự cải thiện đến từ đặc trưng cục bộ, dấu vết mức thấp hay chỉ do model có nhiều tham số hơn.

Do đó, nghiên cứu không tập trung vào việc xây dựng ngay một model gồm nhiều thành phần, mà tập trung vào việc **kiểm chứng liệu các mức representation khác nhau có thực sự cung cấp thông tin bổ sung cho nhau dưới điều kiện nguồn sinh thay đổi hay không.**

4. Câu hỏi nghiên cứu

Câu hỏi nghiên cứu chính được xác định như sau:

Các đặc trưng cục bộ và dấu vết forensic mức thấp có cung cấp thông tin bổ sung cho đặc trưng toàn ảnh của DINOv3 trong việc generalization sang các nguồn khuôn mặt AI chưa từng xuất hiện trong quá trình huấn luyện hay không?

Để trả lời câu hỏi này một cách rõ ràng, nghiên cứu được chia thành bốn câu hỏi nhỏ.

RQ1: Đặc trưng cục bộ từ DINOv3 có cải thiện khả năng generalization sang nguồn sinh chưa từng thấy so với chỉ sử dụng đặc trưng toàn ảnh hay không?

RQ2: Dấu vết forensic mức thấp có cung cấp thêm thông tin ngoài những gì DINOv3 đã học được hay không?

RQ3: Nếu đặc trưng cục bộ và dấu vết mức thấp đều cho thấy giá trị riêng, việc kết hợp các nguồn thông tin này có tốt hơn từng nhánh riêng và các cách kết hợp hai nhánh hay không?

RQ4: Trong điều kiện tập train nhỏ, DINOv3 được giữ cố định và DINOv3 được tinh chỉnh với số lượng tham số nhỏ khác nhau như thế nào về khả năng thích nghi với dữ liệu train và generalization sang nguồn mới?

5. Vai trò của DINOv3 trong nghiên cứu

DINOv3 không được lựa chọn chỉ vì đây là một model mới hoặc có hiệu năng cao. Trong nghiên cứu này, DINOv3 đóng vai trò là một nền tảng representation thống nhất để kiểm tra giả thuyết.

Từ cùng một backbone, nhóm có thể lấy cả đặc trưng toàn ảnh và đặc trưng ở mức patch. Nhờ đó, khi so sánh giữa mô hình chỉ dùng thông tin toàn ảnh và mô hình bổ sung thông tin

cục bộ, các yếu tố khác được giữ tương đối ổn định. Điều này giúp việc phân tích nguyên nhân của sự thay đổi kết quả rõ ràng hơn.

Ngoài ra, DINOv3 được huấn luyện để học representation thị giác tổng quát chứ không được huấn luyện trực tiếp cho bài toán phát hiện ảnh AI. Vì vậy, model này phù hợp để kiểm tra một câu hỏi quan trọng: **representation thị giác tổng quát đã chứa bao nhiêu thông tin cần thiết cho việc phát hiện ảnh AI, và những loại thông tin nào vẫn còn thiếu?**

DINOv3 vì thế được xem là công cụ kiểm chứng giả thuyết, không phải đóng góp chính của nghiên cứu.

6. Xác định các loại đặc trưng sử dụng

Để tránh làm thí nghiệm quá rộng, nghiên cứu cần xác định rõ ngay từ đầu hai loại đặc trưng bổ sung.

Đối với đặc trưng cục bộ, nhóm sử dụng các patch representation lấy trực tiếp từ DINOv3. Các patch này biểu diễn thông tin tại những vùng nhỏ trên ảnh. Trong thí nghiệm chính, nhóm sẽ lựa chọn một phương pháp tổng hợp cố định để tránh thay đổi quá nhiều yếu tố cùng lúc.

Đối với dấu vết mức thấp, nhóm ưu tiên sử dụng image residual hoặc high-frequency residual. Lý do là residual có thể làm giảm ảnh hưởng của nội dung ngữ nghĩa và giữ lại nhiều thông tin liên quan đến texture, noise và quá trình hình thành ảnh. Đây là loại thông tin có bản chất khác với representation của DINOv3 và phù hợp để kiểm tra tính bổ sung.

Các phương pháp dựa trên FFT hoặc DCT có thể được xem xét ở giai đoạn bổ sung nếu còn thời gian, nhưng không phải giả thuyết chính ban đầu.

7. Giả thuyết nghiên cứu

H1: Việc bổ sung đặc trưng cục bộ từ DINOv3 vào đặc trưng toàn ảnh sẽ cải thiện AUROC và/hoặc Balanced Accuracy trên tập kiểm tra gồm các nguồn sinh chưa xuất hiện trong huấn luyện so với mô hình chỉ sử dụng đặc trưng toàn ảnh.

H2: Đặc trưng residual sẽ cung cấp thông tin bổ sung ngoài đặc trưng Global và Local của DINOv3, thể hiện qua việc cải thiện AUROC hoặc Balanced Accuracy và sửa được một phần các trường hợp mà DINOv3 dự đoán sai.

H3: Nếu H1 và H2 được xác nhận, việc kết hợp Global, Local và Residual sẽ cho kết quả tốt hơn từng nhánh riêng và các phương án kết hợp hai nhánh trên tập kiểm tra nguồn sinh chưa từng thấy.

H4: Với tập train nhỏ, phương pháp tinh chỉnh tiết kiệm tham số được kỳ vọng tạo ra sự cân bằng tốt hơn giữa accuracy trên dữ liệu cùng phân phối và khả năng generalization so với fine-tuning toàn bộ model.

Các giả thuyết này đều có thể được kiểm chứng trực tiếp bằng kết quả thực nghiệm. Nếu một thành phần không mang lại cải thiện rõ ràng, nhóm sẽ không mặc định giữ thành phần đó trong model cuối cùng.

8. Quy trình đánh giá

Khả năng generalization sang nguồn sinh chưa từng thấy được xác định là quy trình đánh giá chính của nghiên cứu.

Dữ liệu cần được chia theo nguồn hoặc generator nếu thông tin này có thể xác định được. Một hoặc nhiều nguồn sẽ được giữ hoàn toàn khỏi tập train và chỉ sử dụng để kiểm tra. Ví dụ, model có thể được huấn luyện trên các nguồn A, B và C, sau đó đánh giá trên nguồn D chưa từng xuất hiện trong quá trình huấn luyện. Nếu số lượng nguồn đủ lớn, có thể lặp lại thí nghiệm với nhiều nguồn được giữ lại khác nhau.

Các chỉ số chính gồm AUROC và Balanced Accuracy. Accuracy và F1 được sử dụng như các chỉ số bổ sung. Ngoài đánh giá theo nguồn sinh, model cũng được kiểm tra dưới các biến đổi ảnh như JPEG compression, resize, blur và crop. Đây là trực đánh giá thứ hai nhằm xem các đặc trưng forensic có còn hữu ích sau quá trình xử lý ảnh hay không.

9. Quy trình thực nghiệm

Quá trình thực nghiệm được thực hiện theo hướng từ đơn giản đến phức tạp.

Đầu tiên, nhóm thực hiện khảo sát dữ liệu để kiểm tra nguồn ảnh, cân bằng lớp, resolution, chất lượng JPEG, cách crop và các yếu tố có thể tạo shortcut.

Tiếp theo, nhóm xây dựng mô hình cơ sở gồm Frozen DINOv3 + đặc trưng toàn ảnh + Linear hoặc MLP classifier. Đây là mốc so sánh cho toàn bộ nghiên cứu.

Sau khi có baseline, nhóm kiểm tra RQ1 bằng cách bổ sung đặc trưng cục bộ trong khi giữ nguyên các yếu tố khác.

Tiếp theo, nhóm xây dựng nhánh residual và kiểm tra riêng khả năng phân loại cũng như mức độ trùng lặp lỗi giữa nhánh này với DINOv3. Đây là bước kiểm chứng RQ2.

Chỉ khi đặc trưng Local hoặc Residual cho thấy bằng chứng rõ ràng về giá trị bổ sung, nhóm mới thực hiện thí nghiệm kết hợp đầy đủ để trả lời RQ3.

Cuối cùng, sau khi cấu trúc đặc trưng đã tương đối ổn định, nhóm mới so sánh Frozen DINOv3 với phương pháp tinh chỉnh tiết kiệm tham số và, nếu điều kiện cho phép, fine-tuning toàn bộ model. Fine-tuning được xem là một yếu tố thực nghiệm, không phải đóng góp chính của nghiên cứu.

10. Đóng góp dự kiến

Đóng góp của nghiên cứu không nằm ở việc ghép nhiều module thành một kiến trúc mới.

Trọng tâm của nghiên cứu là kiểm chứng có hệ thống mức độ bổ sung giữa đặc trưng toàn ảnh, đặc trưng cục bộ và dấu vết forensic mức thấp khi nguồn ảnh AI thay đổi.

Thông qua các thí nghiệm tách biệt từng thành phần, nhóm kỳ vọng làm rõ ba vấn đề: DINOv3 toàn ảnh đã học được những gì, đặc trưng cục bộ bổ sung được gì và residual còn cung cấp loại thông tin nào mà DINOv3 chưa nắm bắt được.

Ngay cả trong trường hợp model kết hợp đầy đủ không phải model tốt nhất, nghiên cứu vẫn có giá trị nếu chỉ ra rõ loại representation nào giúp generalization và trong điều kiện nào.

11. Kết quả dự kiến

Kết quả cuối cùng dự kiến gồm một baseline DINOv3 có thể tái lập, một quy trình đánh giá theo nguồn sinh chưa từng thấy, các thí nghiệm so sánh Global, Local và Residual, phân tích lỗi giữa các nhánh, đánh giá robustness và thí nghiệm về ảnh hưởng của fine-tuning.

Mục tiêu cuối cùng không chỉ là xác định model nào đạt accuracy cao nhất, mà quan trọng hơn là trả lời được câu hỏi:

Loại thông tin nào thực sự giúp model phát hiện khuôn mặt AI khi gặp một nguồn sinh mới, và bằng chứng thực nghiệm nào chứng minh cho điều đó?

Đây sẽ là trục chính để nhóm triển khai thí nghiệm và xây dựng báo cáo nghiên cứu ở các giai đoạn tiếp theo.